

Módulo 3

Sebastián Buitrago Gómez

Sebastián Ciro

Juan Esteban Marulanda Ayala

Docente:

Juan Camilo España Lopera

Universidad de Antioquia

Facultad de Ingeniería

Ingeniería industrial

Aplicaciones de la Analítica

Medellín

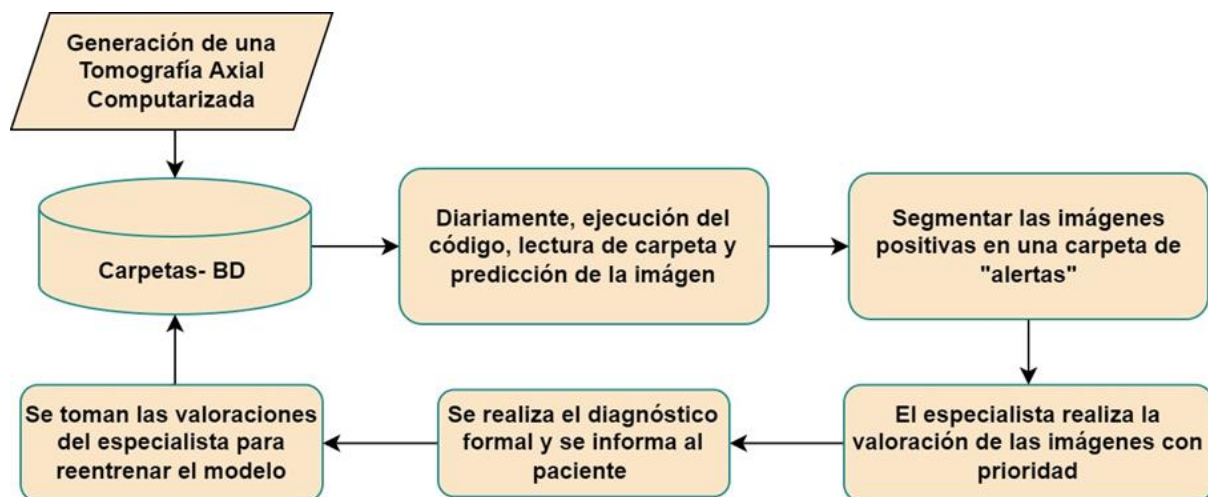
2023-1

a. Diseño de solución propuesto.

DiagnostiCenter es una entidad que presta servicios de imagenología convencional y especializada. Su misión se basa especialmente en el respaldo relacionado con estudios cerebrales y ha incrementado su capacidad tecnológica, específicamente para los servicios relacionados con valoraciones craneales y encefálicas. Dentro las ya mencionadas valoraciones, están aquellas neurológicas como los aneurismas laterales, el alzhéimer o el Parkinson.

Esta última, en particular, tiene diferentes factores que afectan un resultado oportuno como, por ejemplo, una valoración detallada y técnica del nivel de los ganglios basales y el nivel de los ventrículos laterales, en términos de servicio, los resultados tienden a tardar días en ser leídos por un especialista y la cantidad de imágenes es amplia para los pocos neurólogos avalados para realizar lectura.

Por lo anterior, sin dejar de mencionar lo que implica un tardío diagnóstico sobre un paciente, la entidad requiere de una herramienta que permita realizar valoraciones más oportunas. Un modelo que permita definir si una tomografía axial computarizada tiene características de una persona con alzhéimer o si es normal. En sí, el modelo es un apoyo, ya que se generará una alarma para que el especialista haga una rectificación con mayor prioridad, precisión y detalle.



Por ello nos apoyaremos en herramientas de machine learning usando redes neuronales con el objetivo de agilizar el diagnóstico y dar una atención más rápida a los pacientes que tienen indicios de la enfermedad, algunos de los beneficios de la utilización de estas herramientas son los siguientes:

1. **Mayor precisión en el diagnóstico:** Las redes neuronales tienen la capacidad de analizar grandes cantidades de datos y reconocer patrones que pueden ser difíciles de detectar por los seres humanos. Esto permite un diagnóstico más preciso y temprano del Alzheimer.
2. **Mejora en la eficiencia del diagnóstico:** La utilización de redes neuronales puede mejorar la eficiencia del proceso de diagnóstico, ya que pueden analizar grandes


volúmenes de datos en cuestión de minutos, lo que permite ahorrar tiempo y recursos en comparación con los métodos tradicionales de diagnóstico.

3. **Detección temprana del Alzheimer:** La detección temprana del Alzheimer es clave para un tratamiento efectivo. Las redes neuronales pueden detectar los primeros signos de la enfermedad, incluso antes de que aparezcan los síntomas, lo que permite a los médicos tomar medidas preventivas y evitar el progreso de la enfermedad.
4. **Personalización del tratamiento:** Las redes neuronales pueden analizar datos genéticos y clínicos para personalizar el tratamiento para cada paciente. Esto puede mejorar la eficacia del tratamiento y reducir los efectos secundarios.

b. Análisis exploratorio y selección de variables

Para la exploración de datos, se requiere establecer como primera instancia la procedencia de estos, esta base fue extraída desde el repositorio Kaggle con el nombre de “Alzheimer's Disease Multiclass imaging data”. Una vez extraídos los datos se identifica que la base de datos posee dos carpetas que contienen imágenes, la carpeta AD contiene sujetos con diagnóstico positivo de Alzheimer, y la carpeta CN contiene imágenes de personas sin la enfermedad, siendo así el objetivo del modelo es entrenarlo para que logre identificar las diferencias entre ambos tipos de imagen.

Para el análisis de las variables se obtuvo que la carpeta AD contiene 1124 archivos de tipo imagen y la carpeta CN contiene 1440 igualmente archivos de tipo imagen, lo que se realizó con las imágenes fue una nueva, lo primero que se hizo fue verificar que las imágenes si estuvieran en un formato tipo JPG o JPEG ya que es el formato que se necesita para la aplicación del modelo, también se invirtieron los colores para usar el estándar de RGB, adicional a esto identificamos los máximos y los mínimos de píxeles de las imágenes; por otro lado, lo que se hace es reducir el tamaño de las imágenes ya que no se tiene suficiente capacidad de cómputo para procesar imágenes con representaciones vectoriales de hasta 130.560 dimensiones. Al momento de cambiar el tamaño de cada imagen se obtuvo que cada una de ellas queda representada en un array de 30.000 datos. Luego se guardan los datos de entrenamiento y prueba para ser procesados en el script de modelos.



A continuación, se cargan los datos y se normalizan para que queden en un rango de 0 a 1. Luego se construye la arquitectura de la primera red neuronales la cual se hizo *Fully Connected*; para definirla lo primero que se hace es, con la opción *Flatten* de *Keras*, recibir los vectores de 3 dimensiones y convertirlo en un vector de una sola dimensión; después, con

la función *Dense*, se agregan las capas completamente conectadas de la red neuronal, la primera con 128 neuronas y con la función de activación *relu* (*Rectified Linear Unit*) que lo que hace es que si el valor es negativo lo reemplaza por cero y si es positivo lo deja igual, la segunda capa con 64 neuronas y con la misma función de activación y la tercera con 1 neurona con la función de activación *sigmoid*. Esta red neuronal nos dio con sobreajuste porque la métrica auc en entrenamiento fue igual a 0.99 mientras en prueba fue de 0.52.

Por lo anterior se procedió a realizar una red neuronal aplicando *regularización dropout* y *L2*, para el primer caso lo que se hace es borrar un porcentaje de neuronas; para esto se dejó la misma red neuronal agregándole una línea de código después de cada capa donde se usa el *dropout* para borrar el porcentaje asignado de neuronas (30%). Para la segunda *regularización L2*, y lo que hace es agregarle un componente a la función objetivo en la que el tamaño del parámetro penaliza la función objetivo. Para este caso nos siguió dando con sobreajuste.

Por último, lo que se hizo fue usar la afinación de los hiperparámetros mediante *keras-tuner* que lo que hace es evaluar en una red neuronal definida el optimizador que mejores resultados tiene.